

数据格式定义

对于原始矩阵数据，按照 32×32 的tile进行量化，每个tile分为4个子块，每个子块共享指数表示。定义：

$$x \approx q \cdot 2^e$$

q 是整数部分，用int32， e 是指数部分，用int8

一个tile共有4个指数： e_0, e_1, e_2, e_3 。

反量化： $\hat{x} = q \cdot 2^e$

量化算法

对于每个子块的浮点数据 X

1. 计算百分位数值: $a = \text{percentile}(|X|, p)$, $p = 99.0$, 具体多少到时候拿到具体例子定。
2. 确定整数的有效位宽 B_{eff} , $Q_{max} = 2^{B_{eff}-1} - 1$
3. 选择量化指数 $e = \lceil \log_2(\frac{a}{Q_{max}}) \rceil$
4. 先裁剪: $X_c = \text{clip}(X_{ij}, a, -a)$, 计算整数 $q_{ij} = \text{clip}(\text{round}(\frac{X_c}{2^e}), Q_{max}, -Q_{max})$
5. 输出 q, e

密度检查

为了避免全0/1，量化后统计 $r = \frac{\#|q| \geq 2}{256}$ 。若 $r < r_{min}$ ，说明指数过大，导致大量信息被压扁，令 $e = e - 1$ 。重新量化。同时监控裁剪比例。

extend-add

父节点frontal 某个 16×16 的子块存为 (q_p, e_p) ，子阶段的update 对应的子块是 (q_u, e_u) 。在执行extend-add需要进行指数对齐。目前的做法是对齐到父节点指数。

$$q_u^{aligned} = \text{round}(q \cdot 2^{e_u - e_p})$$
$$q_p \leftarrow \text{sat}(q_p + q_u^{aligned})$$

会出现的问题

在算法部分，需要进行 32×32 的LU分解，需要进行消元处理。标准都是in-place LU做法：

- 选主元 $p = A_{kk}$ ，目前会选择当列中的最大值。(为什么不能是小值，因为除法可能会导致过大溢出)
- 对于每个 $i > k$ 计算乘子 $l_{ik} = \frac{A_{ik}}{p}$
- 对应 L 部分填入 l_{ik}
- 更新: $A_{ij} \leftarrow A_{ij} - l_{ik} \cdot A_{kj}$

其中的第二步，现在的CPU做出来的应该就是0或者误差巨大，并不能达到预期的效果。

解决方案

一个解决方法是定点乘子，把除法变成带小数除法.用 F 来表示一个固定的小数位，乘子表示为Q格式

$$l_{ik}^{(Q)} = \text{round}\left(\frac{A_{ik}2^F}{p}\right)$$
$$A_{ij} \leftarrow A_{ij} - (l_{ik}^{(Q)} A_{kj}) \gg F$$

目前CPU是RV64，但为了保证 $A_{ik}2^F$ 不溢出，因此会将数据量化为32bit